Universität Rostock

ANFORDERUNGEN

Vom Problem zum Prompt

Joern Ploennigs · AI4SC

‘The Connoisseur’ by Norman Rockwell

Hörsaalfrage

Der Agent meldet: Aufgabe erledigt. Woher wissen Sie, ob das stimmt?



WARUM ANFORDERUNGEN?

Ein Satz, drei Ergebnisse

Prompt

> „Berechne den mittleren Wasserstand.“

Beispieldaten einer Messstation, –999 steht für „Messwert fehlt“:

Zeit in h	0	1	2	6
Pegel in m	2,30	2,32	–999	2,60

Tang et al.: How Coding Agents Fail Their Users, arXiv:2605.29442, 2026

Drei Programme, drei Ergebnisse

- Mittelwert aller Einträge: –247,945 m
- Mittelwert der gültigen Werte: 2,407 m
- Zeitgewichteter Mittelwert (Trapezregel): 2,435 m

Welche Lesart meint der Auftraggeber? Der Satz legt es nicht fest.

Vier Fehlerarten von Agenten

38,3 %

Einschränkung verletzt

Der Agent verletzt eine ausdrücklich genannte Vorgabe. Abhilfe: Randbedingungen kurz, dauerhaft und prüfbar festhalten

27,0 %

Absicht missverstanden

Der Agent füllt eine Lücke falsch. Abhilfe: vollständige funktionale Anforderungen

22,6 %

Ungenaue Selbstauskunft

Der Agent meldet Erfolg, der nicht stimmt. Abhilfe: prüfbare Akzeptanzkriterien

10,2 %

Eigenmächtige Erweiterung

Der Agent handelt über den genannten Umfang hinaus. Abhilfe: Umfang und Nicht-Ziele festhalten und prüfen

Tang et al.: How Coding Agents Fail Their Users, arXiv:2605.29442, 2026. Anteile an allen Episoden, gerundet

Der Agent fragt nicht nach und meldet „fertig“

Er fragt nicht nach

Ohne Aufforderung fragen Modelle bei unvollständigen Aufgaben meist nicht nach. Dürfen sie Rückfragen stellen, erreichen Claude-Modelle etwa 80 % (Sonnet 3.5) bis 89 % (Sonnet 4) der Leistung bei vollständiger Aufgabenbeschreibung.

Vijayvargiya et al.: Ambig-SWE, arXiv:2502.13069, 2026
Anthropic: Best practices for Claude Code, 2026

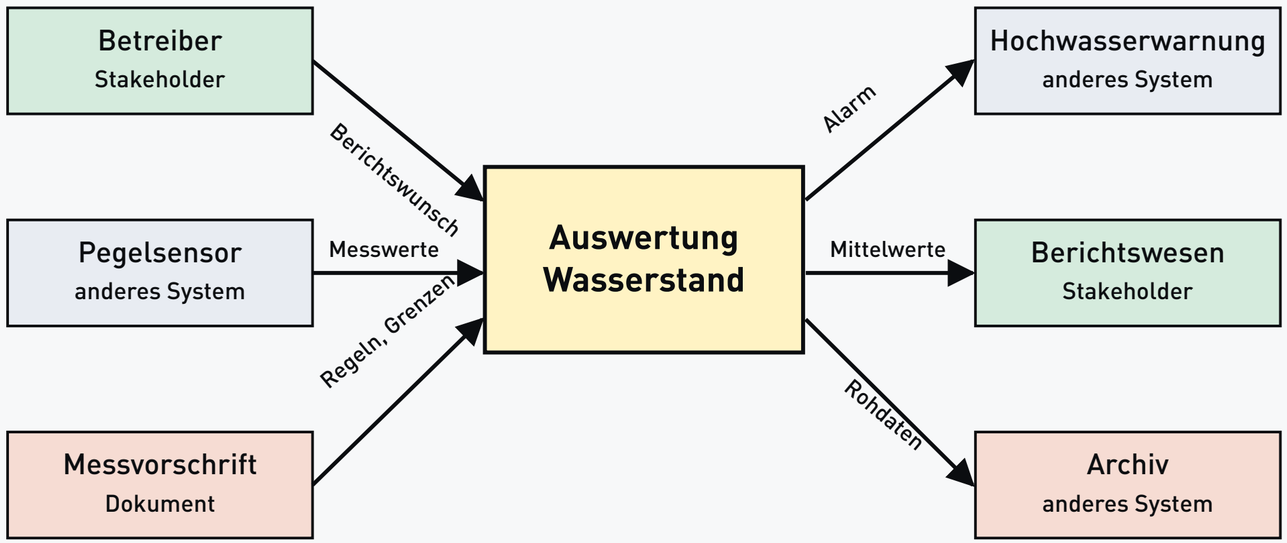
Er hört auf, wenn es fertig aussieht

„Claude stops when the work looks done. Without a check it can run, ‚looks done‘ is the only signal available.“

Wer keine Prüfung mitliefert, wird selbst zur Prüfinstanz.

ANFORDERUNGEN ERMITTELN

Der Kontext bestimmt die Quellen



Drei Arten von Quellen

- Stakeholder: Betreiber, Berichtswesen
- Dokumente: Messvorschrift, Normen
- Andere Systeme: Sensor, Warnsystem, Archiv

Die Systemgrenze legt fest, wer Anforderungen stellt.

Glinz et al.: IREB CPRE Foundation Level Handbook, Abschnitte 3.4.2 und 4.1, 2022

Fünf Familien von Ermittlungstechniken

Familie	Techniken	Findet vor allem	Beispiel Messstation
Befragung	Interview, Fragebogen	Ausdrücklich genannte Wünsche	Betreiber nach dem Berichtsformat fragen
Zusammenarbeit	Workshop, Crowd	Ausdrücklich genannte Wünsche	Tragwerk, Haustechnik und Betreiber legen Messgrößen fest
Beobachtung	Feldbeobachtung, Apprenticing	Selbstverständliches	Begehung der Messstation, Ablesen und Ausfälle verfolgen
Artefakte	Systemarchäologie, Feedback-Analyse, Wiederverwendung	Selbstverständliches und Wünsche	Altes Auswerteskript, Störungsprotokolle, Messvorschrift
Kreativität und Design	Brainstorming, Analogie, Prototyp, Szenario	Neue Ideen, Qualitätsanforderungen	Handrechnung als Prototyp, Szenario Hochwasser

Glinz et al.: IREB CPRE Foundation Level Handbook, Abschnitt 4.2, 2022

Beobachten und Artefakte auswerten

Beobachtung

- Feldbeobachtung: zusehen, ohne einzugreifen
- Apprenticing: mitarbeiten und von erfahrenen Nutzern lernen, einen Tag bis mehrere Wochen

Findet, was so üblich ist, dass es niemand sagt.

Beispiel: Wie liest das Personal die Messstation tatsächlich ab, und wo notiert es Ausfälle?

Artefakte

- Systemarchäologie: Altsystem, Dokumentation, Code, Testfälle
- Dokumente: Normen, Vorschriften, Arbeitsanweisungen
- Feedback-Analyse: Fehlerberichte, Protokolle

Vorsicht: Altes kann veraltet sein.

Beispiel: Das alte Auswerteskript zeigt, dass –999 ein Ausfall ist.

Glinz et al.: IREB CPRE Foundation Level Handbook, Abschnitte 4.1.2 bis 4.2.2, 2022

Entwerfen und ausprobieren

Kreativität

- Brainstorming: Ideen sammeln, Urteil aufschieben
- Analogie: ein ähnliches Problem aus einer anderen Branche übertragen

Findet neue Ideen.

Design

- Prototyp: von der Skizze bis zur Vorabversion
- Szenario und Storyboard: Ablauf mit Akteuren, auch Ausnahmen

Findet Qualitätsanforderungen, Selbstverständliches und Randbedingungen.

Beispiel: Handrechnung oder Tabelle als Prototyp, Szenario „Hochwasser, Sensor fällt aus“.

Glinz et al.: IREB CPRE Foundation Level Handbook, Abschnitt 4.2.3, 2022

ANFORDERUNGEN FESTLEGEN

Drei Arten von Anforderungen

Funktional

Ergebnis, Verhalten oder Interaktion, die ein System liefern soll

- Der Mittelwert wird zeitgewichtet berechnet
- Ein Messwert –999 wird ignoriert

Qualität

Qualitätsaspekte, die die funktionalen Anforderungen nicht abdecken

- Auswertung eines Tages dauert höchstens 1 s
- Das System bleibt bei Sensorausfall betriebsbereit

Randbedingung

Beschränkt den Lösungsraum über das Nötige hinaus

- Nur die Python-Standardbibliothek
- Ausgabe im Format des Warnsystems

Glinz et al.: IREB CPRE Foundation Level Handbook, Abschnitt 1.1, 2022

Eine einzelne Anforderung prüfen

Sechs Kriterien (IREB)

- Angemessen: beschreibt echte, abgestimmte Bedürfnisse
- Notwendig: gehört zum Umfang des Systems
- Eindeutig: alle verstehen dasselbe
- Vollständig: nichts zum Verständnis fehlt
- Verständlich: die Zielgruppe versteht sie
- Prüfbar: Erfüllung lässt sich eindeutig feststellen

Glinz et al.: IREB CPRE Foundation Level Handbook, Abschnitt 3.8, 2022

Umschreiben

„Die Auswertung soll schnell und einfach sein.“

„WENN ein Tagesbericht angefordert wird, muss die Auswertung für 144 Messwerte (24 h im 10-Minuten-Raster) in höchstens 1 s ein Ergebnis liefern.“

Der Zahlenwert ist ein Beispielwert, nur die 144 folgen aus dem Messraster.

User Story und Akzeptanzkriterien

Schablone

> Als **[Rolle]** möchte ich **[Anforderung]**, damit **[Nutzen]**.

Akzeptanzkriterien legen fest, wann die Story erfüllt ist.

Beispiel

> Als **Betreiber** möchte ich den mittleren Wasserstand je Tag, damit ich Berichte ohne Handrechnung erstellen kann.

- Gegeben Messwerte bei 0, 1, 2 und 6 h mit 2,30; 2,32; –999; 2,60 m, wenn der Mittelwert berechnet wird, dann ergibt sich 2,435 m (±0,001 m).
- Gegeben nur ein gültiger Messwert, wenn der Mittelwert berechnet wird, dann erscheint eine Fehlermeldung statt einer Zahl.

Fowler: Given When Then, martinfowler.com, 2013

ANFORDERUNGEN FÜR DEN AGENTEN

Die agententaugliche Spezifikation

Abschnitt der Spezifikation	Prompt-Element (03d)	Beugt vor
Ziel und Kontext	Rolle, Kontext	Absicht missverstanden
Funktionale Anforderungen	Aufgabe	Absicht missverstanden
Randbedingungen	Constraint	Einschränkung verletzt
Nicht-Ziele	Constraint	Eigenmächtige Erweiterung
Qualitätsanforderungen, Akzeptanzkriterien	Ausgabeformat und Test	Ungenaue Selbstauskunft

Anthropic: Best practices for Claude Code, Abschnitt „Let Claude interview you“, 2026

Beispiel: Spezifikation für den mittleren Wasserstand

```
Ziel
  mittlerer_wasserstand(zeiten_h, werte_m)
  für Pegeldaten, Meter über Pegelnull

Funktional
  F1  Die Funktion muss den zeitgewichteten
      Mittelwert (Trapezregel) der gültigen
      Werte liefern.
  F2  FALLS ein Messwert -999 ist, DANN muss
      sie ihn ignorieren.
  F3  FALLS weniger als zwei gültige Werte
      vorliegen, DANN muss sie einen
      ValueError auslösen.
```

```
Randbedingungen
  R1  Nur die Python-Standardbibliothek.
  R2  Zeiten in Stunden, aufsteigend.

Nicht-Ziele
  Keine Interpolation, keine Plots,
  Eingaben bleiben unverändert.

Akzeptanz
  A1  Zeiten 0, 1, 2, 6 h; Werte
      2,30; 2,32; -999; 2,60
      ergeben 2,435 m (±0,001 m).
```

Anthropic: Best practices for Claude Code, 2026

Randbedingungen und Abgrenzung ausdrücklich nennen

Ohne

> „Schreibe eine Funktion mittlerer_wasserstand.“

Offen bleiben:

- welche Bibliotheken erlaubt sind
- ob die Eingabelisten verändert werden dürfen
- ob fehlende Werte ergänzt werden sollen

Tang et al.: How Coding Agents Fail Their Users, arXiv:2605.29442, 2026

Mit

> „Schreibe nur die Funktion mittlerer_wasserstand in pegel.py. Nur Standardbibliothek. Die Eingabelisten nicht verändern. Fehlende Werte nicht ergänzen. Keine weiteren Dateien anlegen.“

Jeder Satz verbietet etwas, das ein Agent sonst plausibel tun würde.

Akzeptanzkriterien werden Tests

Jedes Kriterium ergibt mindestens einen Test:

- A1: Beispieldaten ergeben 2,435 m
- F2: Fehlwert –999 wird ignoriert
- F3: weniger als zwei gültige Werte lösen einen Fehler aus

```python
import pytest
from pegel import mittlerer_wasserstand

def test_beispieldaten():
    z, w = [0, 1, 2, 6], [2.30, 2.32, -999.0, 2.60]
    assert mittlerer_wasserstand(z, w) == pytest.approx(2.435, abs=1e-3)

def test_fehlwert_wird_ignoriert():
    assert mittlerer_wasserstand([0, 1, 2], [2.0, -999.0, 2.0]) == pytest.approx(2.0)

def test_zu_wenige_werte():
    with pytest.raises(ValueError):
        mittlerer_wasserstand([0, 1], [2.0, -999.0])
```

Fowler: Given When Then, martinfowler.com, 2013

Prüfung gegen die Spezifikation

Drei Prüfungen

01 Führen Sie die Tests selbst aus.

02 Lesen Sie die Änderungen gegen die Spezifikation: Wurde etwas hinzugefügt, das dort nicht steht?

03 Lassen Sie eine zweite Sitzung ohne den bisherigen Verlauf gegen die Spezifikation prüfen.

Warum

22,6 % der Episoden: Der Agent beschreibt sein Ergebnis ungenauer, als es ist.

Ein Prüfer ohne die Vorgeschichte bewertet nur Ergebnis und Kriterien.

Anthropic: Best practices for Claude Code, Abschnitt „Add an adversarial review step“, 2026
Tang et al.: How Coding Agents Fail Their Users, arXiv:2605.29442, 2026

Den Agenten fragen lassen

Vor dem Code

> „Ich will [Beschreibung]. Interviewe mich ausführlich. Frage nach Randfällen und Zielkonflikten, nicht nach Offensichtlichem. Schreibe danach eine vollständige Spezifikation in eine Datei.“

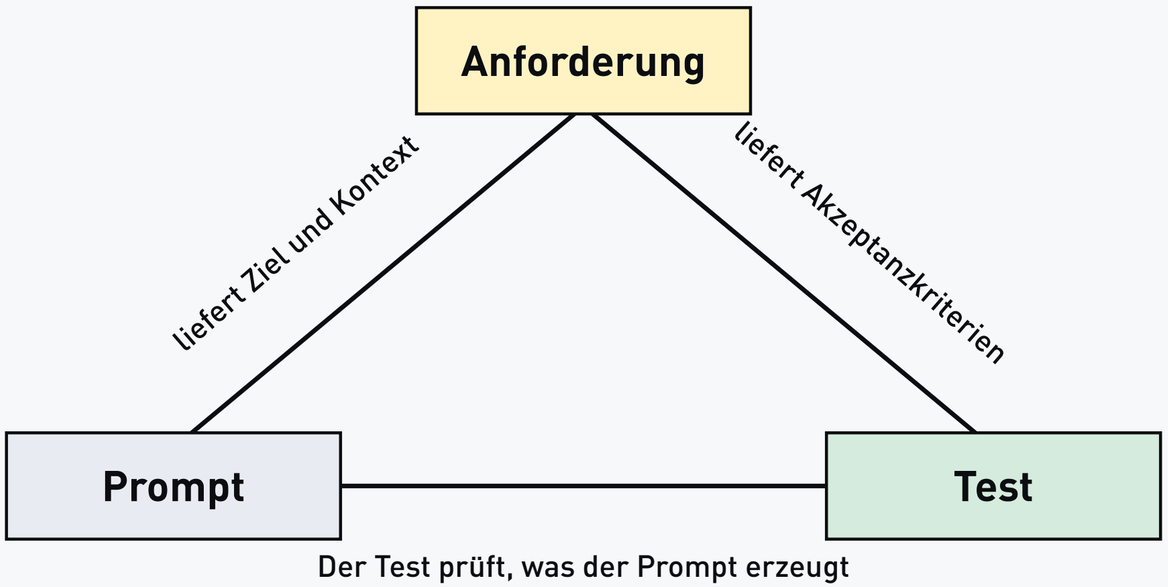
Die Spezifikation prüfen Sie gegen das, was Sie gesammelt haben.

Anthropic: Best practices for Claude Code, 2026
Jin et al.: ReqElicitGym, arXiv:2602.18306, 2026

Grenzen

Im Benchmark ReqElicitGym erreicht das beste von sieben Modellen einen Anteil von 0,32 der impliziten Anforderungen, das niedrigste 0,08. Anforderungen zum Stil erreichen fast 0.

Traceability-Dreieck



Regel

Ändert sich die Anforderung, werden Prompt und Test angepasst.

Ändert sich der Test, werden Anforderung und Prompt geprüft.

Kein Test und kein Prompt ohne Anforderung.

Glinz et al.: IREB CPRE Foundation Level Handbook, Abschnitt 3.8, 2022

Referenzen

Anthropic (2026). Best practices for Claude Code.

Fowler, M. (2013). Given When Then.

Glinz, M., Loenhoud, H. van, Staal, S., & Bühne, S. (2022). *Handbook for the CPRE Foundation Level in accordance with the IREB Standard, Version 1.2.0*. IREB e.V.

Jin, D., Jin, Z., Fang, Z., Li, L., Yang, X., He, Y., & Chen, X. (2026). ReqElicitGym: An Evaluation Environment for Interview Competence in Conversational Requirements Elicitation.

Tang, N., Chen, C., Xu, G., Shi, Y., Huang, Y., McMillan, C., et al. (2026). How Coding Agents Fail Their Users: A Large-Scale Analysis of Developer-Agent Misalignment in 20,574 Real-World Sessions.

Vijayvargiya, S., Zhou, X., Yerukola, A., Sap, M., & Neubig, G. (2026). Ambig-SWE: Interactive Agents to Overcome Underspecificity in Software Engineering.

QUESTIONS