Datenhaltung

Joern Ploennigs · AI4SC



> We don’t have better algorithms. We just have more data.
>
> — Peter Norvig

Ingenieurdaten kommen selten in einer selbst gewählten Idealform an. Meist bestimmt das Werkzeug, das die Daten erzeugt hat, auch das Format: Sensorik liefert CSV, GIS-Werkzeuge oft GeoJSON, Bürosoftware XLSX, CAD und BIM ihre eigenen Austauschformate. Deshalb ist Dateiarbeit keine Nebensache, sondern ein zentraler Teil des Datenmodells.

Dateien als Eingangskanal

Dateien sind Ankunftspunkte für Fachdaten

- Dateien sind nicht nur „Speicher“
- Dateien sind die Form, in der Werkzeuge Daten an uns übergeben
- Das Format wird oft vom Ursprungswerkzeug bestimmt
- Unsere Aufgabe: lesen, verstehen, prüfen, weiterverarbeiten

Engineering-Szenario 1: Messdaten aus dem Feld

Monitoring-Station

- Zeitreihen als `CSV`
- Oft `;` statt `,`
- Fehlwerte als `-9999` oder leer
- Umlaute in Kopfzeilen sind möglich

Fragen vor dem Einlesen

- Welche Kodierung?

- Welches Trennzeichen?
- Hat die Datei eine Kopfzeile?
- Wie sind fehlende Werte markiert?

Engineering-Szenario 2: Modelle aus anderen Werkzeugen

GIS / Umweltinformatik

- Geometrien oft als `GeoJSON`
- Struktur ist verschachtelt
- Attribute liegen in `properties`

BIM / Planung

- Modelle als `IFC`, XML oder JSON-Varianten
- Große Dateien, viele Objekte
- Fachlogik steckt im Format

Die erste fachliche Frage lautet daher selten „Wie programmiere ich Lesen?“, sondern „Was hat das Werkzeug, das die Datei erzeugt hat, eigentlich gemeint?“. Gerade mit KI-generiertem Code ist diese Unterscheidung wichtig, weil das Modell oft ein plausibles, aber falsches Standardformat annimmt.

Speicher und Dateisysteme

Wo liegen unsere Daten?

Smartphones und Tablets

- App-bezogene Datenhaltung
- Starke Kapselung
- Wenig direkte Dateisicht

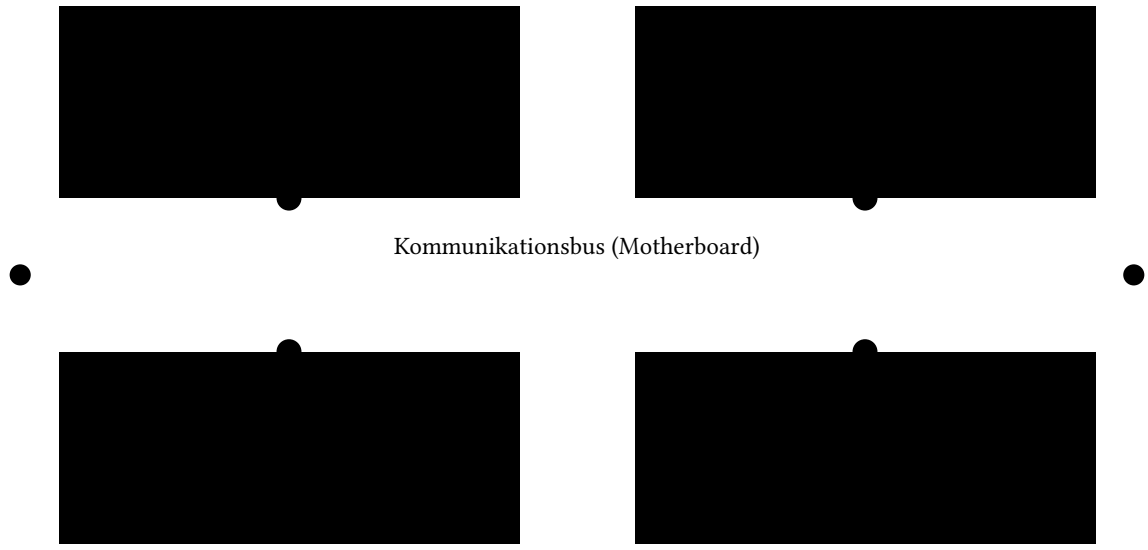
Desktop-PCs

- Dateien in Ordnerstrukturen
- Direkte Arbeit mit Pfaden
- Typisch für Python-Skripte

Web- und Cloudsysteme

- Daten verteilt auf Servern
- Häufig Datenbanken im Hintergrund
- Dateien oft nur Import/Export-Schnittstelle

Speicherhierarchie im Computer



- Register und Cache: sehr schnell, sehr klein
- RAM: schnell, aber flüchtig
- SSD/HDD: langsam im Vergleich, aber dauerhaft
- Dateien liegen im permanenten Speicher

Von RAM zu Datei

Während das Programm läuft

- Variablen im RAM
- Daten können verändert werden
- Inhalt geht beim Ausschalten verloren

Wenn Daten bleiben sollen

- Schreiben in Dateien
- Organisation über Dateisystem
- Identifikation über Pfad und Dateiname

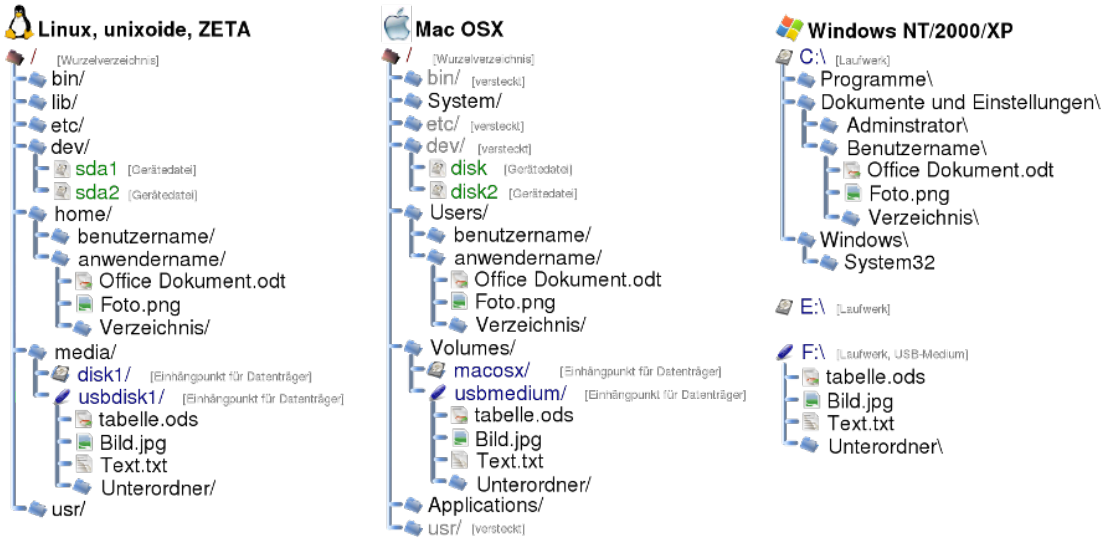
Dateisysteme organisieren Dateien

Desktop

- Hierarchische Ordnerstruktur
- Gut für viele unterschiedliche Dateien
- Schnell unübersichtlich

App- und Cloud-Kontexte

- Stärker gekapselt
- Mehr Sicherheit
- Weniger direkte Kontrolle



Python und Dateisysteme

- `open()` für direktes Lesen und Schreiben
- `os` und `pathlib` für Pfade, Listen, Existenztests
- Textdateien oft zeilenweise lesen
- Binärdateien als Bytes behandeln

Dateien mit Python

Dateien lesen und schreiben

Lesen

- `open(path, "rt")`
- mit `with` automatisch schließen
- `read()`, `readlines()`, Iteration über Zeilen

Schreiben

- `open(path, "wt")`
- `write()` überschreibt im Modus `w`
- für Binärdateien: `rb` und `wb`

KI-generierter Code: Was macht dieser Block?

```
with open("messung.csv", "rt") as fi:
    text = fi.read()
```

- Welchen Datentyp hat `text`?
- Für welche Dateitypen ist das passend?
- Was würde bei einer Binärdatei schiefgehen?

Auflösung

- `text` ist ein `str`
- Passend ist das für Textdateien wie `csv`, `json`, `xml` oder `txt`
- Bei Binärdateien würden Bytes als Text fehlinterpretiert oder schon beim Dekodieren Fehler entstehen

Dateien prüfen, auflisten, löschen

```
from pathlib import Path

pfad = Path("daten")

for datei in pfad.iterdir():
    if datei.is_file():
        print(datei.name)

print(Path("messung.csv").exists())
Path("temp.txt").unlink(missing_ok=True)
```

Formate: Text oder Binär?

Text

- Als Zeichen lesbar
- Gut debugbar
- Beispiele: `txt`, `json`, `xml`, `csv`

Binär

- Als Bytes gespeichert
- Kompakter oder softwaregebunden
- Beispiele: `xlsx`, `zip`, Bilder, Videos

Im Unterricht reicht oft eine grobe Zweiteilung in Text- und Binärdateien. Fachlich entscheidend ist aber die dritte Frage: Welche Struktur erwartet das erzeugende Werkzeug? Zwei Textdateien können sich völlig unterschiedlich lesen lassen, wenn eine flache CSV-Tabelle und die andere eine tief verschachtelte GeoJSON-Datei ist.

Fachformate verstehen

Typische Formate für Ingenieurdaten

Geometrie

- DWG, DXF, IFC
- GeoTIFF, Shapefile
- GeoJSON

Attribute

- CSV
- XLSX
- JSON

Struktur / Austausch

- XML
- JSON
- ZIP als Container

JSON: strukturierte Objekte

- Menschen- und maschinenlesbar
- Nahe an Python-`dict` und `list`
- Gut für APIs und Konfigurationsdaten
- Auch Basis für GeoJSON

```
{
  "name": "Station 7",
  "active": true,
  "values": [12.4, 13.1],
  "location": {"x": 12.10, "y": 54.08}
}
```

GeoJSON: Geometrie plus Attribute

- Standard für geographische Objekte
- Geometrien wie `Point`, `LineString`, `Polygon`
- Attribute typischerweise in `properties`
- Verschachtelung ist normal, nicht die Ausnahme

```
{
  "type": "Feature",
  "geometry": {"type": "Point",
               "coordinates": [12.09, 54.07]},
  "properties": {"name": "OKI"}
}
```

XML: Markup mit Tags

- Älter als JSON, aber weiter verbreitet

- Gut für formalisierte Austauschstandards
- Struktur über öffnende und schließende Tags
- Häufig in Office- und Fachstandards

```
<station>
  <name>Station 7</name>
  <active>true</active>
  <value unit="m">12.4</value>
</station>
```

CSV: Tabellen und Messwerte

- Sehr einfaches Tabellenformat
- Eine Zeile pro Datensatz
- Trennzeichen nicht immer Komma
- Deutsche Daten nutzen oft `;`

```
Zeit;Pegel;Status
08:00;2.41;ok
09:00;;wartung
10:00;2.55;ok
```

XLSX und ZIP: Container statt Klartext

XLSX

- Excel-Arbeitsmappe
- Für Menschen komfortabel
- Intern mehrere XML-Dateien

ZIP

- Verpackt viele Dateien in einer
- Kann Inhalte komprimieren
- Auch Fachformate nutzen ZIP als Hülle

Für Python bedeutet das: Nicht jedes scheinbar „einfache“ Dateiformat ist im Inneren einfach. Eine `.xlsx`-Datei wirkt wie eine einzelne Tabelle, ist aber technisch ein Container aus mehreren Dateien. Deshalb sollte das Lesewerkzeug zum Format passen, nicht nur zur Dateiendung.

Ein Skript, drei Formate

```
import json
import pandas as pd
import xml.etree.ElementTree as ET
```

```
messung = pd.read_csv("messung.csv", sep=";", encoding="latin-1")

with open("stationen.geojson", "rt", encoding="utf-8") as fi:
    geo = json.load(fi)

xml_baum = ET.parse("station.xml")
xml_wurzel = xml_baum.getroot()

print(messung.head(2))
print(geo["features"][0]["properties"]["name"])
print(xml_wurzel.findtext("name"))
```

- `CSV` lesen wir tabellarisch mit `pandas`
- `GeoJSON` lesen wir als verschachteltes JSON-Objekt
- `XML` lesen wir über Tags und Elemente

KI-Verifikation beim Datei-I/O

Wenn KI Dateicode erzeugt: typische Fehlannahmen

Das Modell nimmt oft an

- UTF-8-Kodierung
- Komma als Trennzeichen
- Erste Zeile ist Header
- Fehlwerte sind leer

Engineering-Daten sind oft anders

- `latin-1` oder Windows-Kodierung
- `;` oder Tabulator
- Metazeilen vor dem Header
- `-9999`, `NA`, `---`

Verifikation mit `pandas`

```
import pandas as pd

probe = pd.read_csv(
    "messung.csv",
    sep=";",
    encoding="latin-1",
    na_values=["-9999", "NA", ""]
)

print(probe.head())
print(probe.dtypes)
```

- Erst kleine Probe lesen

- Kopfzeile und Datentypen prüfen
- Fehlwerte sichtbar machen

KI-Code-Reading: Wo kann dieser Vorschlag scheitern?

```
df = pd.read_csv("messung.csv")
```

1. Stimmt das Trennzeichen?
2. Stimmt die Kodierung?
3. Ist Zeile 1 wirklich der Header?
4. Werden Fehlwerte korrekt erkannt?

Agentic Workflow für Datei-I/O

> **Agentic workflow:** Wenn KI Code zum Einlesen von Dateien erzeugt: 1. Prüfe zuerst Kodierung und Trennzeichen. 2. Kontrolliere Header-Behandlung und fehlende Werte. 3. Teste auf einer kleinen echten Stichprobe vor dem Gesamtdatensatz. 4. Präzisiere den Prompt mit Formatwissen aus dem Ursprungstool.

Mini-Checkliste vor dem Vollimport

Fachlich

- Welches Tool hat die Datei erzeugt?
- Welche Struktur erwarte ich?
- Was bedeutet ein fehlender Wert?

Technisch

- `encoding`
- `sep`
- `header`
- `na_values`

Grenzen von Dateien

Dateien sind praktisch, aber begrenzt

Stärken

- Einfach austauschbar
- Direkt sichtbar
- Gut für Import/Export

Grenzen

- Gleichzeitiger Zugriff schwierig
- Versionierung und Konsistenz mühsam
- Suchen, Filtern, Verknüpfen schnell aufwendig

- Deshalb reichen Dateien für gemeinsame, wachsende Datenbestände oft nicht mehr aus

Ausblick

- In `11b_UIDesign` lesen Dashboards Daten aus Dateien oder APIs ein
- In `12b_Datenbanktypen` sehen wir, warum Dateien allein oft nicht reichen
- Später folgen relationale Datenbanken als robustere Mehrnutzer-Lösung

Lesson Learned

- Dateien sind der übliche Eingangskanal für technische Daten
- Formatwahl ist eine Modellierungsentscheidung
- Textformat heißt nicht automatisch „einfach“
- KI-generierter Dateicode muss immer an echten Beispieldaten verifiziert werden

Quiz

Bibliographie